数据集生成脚本说明(gen_data.py)

一、脚本说明

本脚本用于从大型 **PSD / HDF5 模态数据文件** 中生成神经网络训练与推理所需的数据集，主要功能包括：

- 构造节点对输入特征（`nodePairs`）
- 生成对应的标签数据：
  - 位移（`Dis`）
  - 应力（`Stress`）
  - 应变（`Strain`）
- 执行输入与输出的 **归一化 / 标准化** 处理
- 划分训练集与测试集
- 保存推理阶段所需的 `scale` 参数文件

该脚本是整个 **模型训练、评估以及 ONNX 推理流程的数据源头**，其输出结果将被后续所有流程直接依赖。

二、脚本整体工作流程

数据集生成流程如下所示：

```
读取 PSD / HDF5 文件
 ├─ 分块读取节点与模态数据（避免内存溢出）
 ├─ 构造节点对输入特征（nodePairs）
 ├─ 计算模态位移 S
 ├─ 计算 Stress / Strain（可选）
 ├─ 随机划分训练集 / 测试集索引
 ├─ 输入特征归一化与标准化
 ├─ 按输出维度拆分标签数据
 ├─ 保存训练集与测试集数据
 └─ 生成推理阶段使用的 scale.json
```

三、PSD / HDF5 数据读取逻辑

3.1 分块读取函数 `read_dataset_in_chunks()`

为安全、高效地处理超大规模 PSD / HDF5 数据集，脚本中实现了统一的分块读取接口：

```
def read_dataset_in_chunks(dset, block_rows=1_000_000):
```

作用：

- 分批读取 HDF5 数据
- 避免一次性加载导致内存溢出

- 最终统一 reshape 成列向量

3.2 关键数据来源

数据	含义
`Node/Coordinate`	节点坐标
`Mode/AttachMode`	模态位移数据
`Mode/AttachStressMode`	应力模态
`Mode/AttachStrainMode`	应变模态（可选）
`Mode/AttachModeDofId`	DOF 映射关系

四、向量化数据构造逻辑

采用**并行索引与向量化计算**：

- 整体样本空间按照 **模态数 × 节点数** 一次性展开
- 使用 `meshgrid` + 展平索引构造完整的 `(i, j)` 组合
- 通过 `searchsorted` 实现模态节点索引的批量映射，避免逐元素查找
- 除 `dof_i × dof_j` 的 **3×3 极小循环**外，其余计算全部为向量化操作

最终生成的数据包括：

- 位移特征 `Dis`（9 维）
- 应力 / 应变特征 `Stress / Strain`（18 维）

该设计在大规模样本场景下显著降低了 Python 层循环开销，整体数据生成性能主要受 **NumPy 底层并行能力与内存带宽** 限制。

五、训练 / 测试集划分

```
np.random.seed(42)
indices = np.random.permutation(total_size)
```

特点：

- 固定随机种子
- 保证实验可复现
- 当前 `test_ratio = 1.0`（即全量测试）

六、输入归一化与标准化

6.1 数值缩放

```
scale_node = 1e1 / max(abs(train_inputs))
```

目的：

- 限制输入量级
- 减少梯度不稳定问题

6.2 标准化（StandardScaler）

```
scaler = StandardScaler()
train_inputs = scaler.fit_transform(train_inputs)
test_inputs = scaler.transform(test_inputs)
```

并保存：

- `dataset/{name_psd}/scaler_inputs.pkl`

注意事项：

- 训练、评估与推理阶段 **必须使用同一个** `scaler`

七、标签生成与缩放

7.1 gen_labels() 函数说明

作用：

- 生成训练集与测试集标签
- 对标签数据进行数值缩放，保证不同维度数值量级一致
- 按输出维度拆分标签并保存为独立文件
- 生成对应的 `scale_*.json` 参数文件

7.2 主要参数说明

参数	含义
`name_psd`	数据集名称
`S`	原始标签矩阵（Dis / Stress / Strain）
`Stype`	标签类型：Dis / Stress / Strain
`num`	输出维度数量
`test_indices`	测试集索引

7.3 标签缩放策略

```
scale_S = 1e3 / max(abs(S))
```

目的：

- 将物理量映射到神经网络友好的数值范围
- 推理阶段必须使用**同一套 scale 参数**

输出文件结构

- `dataset/{name_psd}/{Stype}/`
  - `train/`
    - `train_labels{dim}.npy`
    - `train_labels_scaled{dim}.npy`
  - `test/`
    - `test_labels{dim}.npy`
    - `test_labels_scaled{dim}.npy`
  - `scale_{Stype}.json`

八、相关参数输出

最终生成的参数文件为：

- `inference/dataset/{name_psd}/scale.json`

内容包括：

参数	说明
`node_count`	节点数量
`scale_node`	输入缩放因子
`scale_Dis`	位移缩放参数
`scale_Stress`	应力缩放参数
`scale_Strain`	应变缩放参数

该文件是 **ONNX 推理阶段的关键依赖文件**，必须与训练与数据生成阶段保持严格一致。

作者： 雷尚谕
日期： 2025-12